

Практическая работа. Модуль 4 (экзамен)

Дисциплина ETL-процессы

Тема реализация ETL-процесса

Форма проверки

Задание проверяется преподавателем

Имя преподавателя

Артём Озерков

Время выполнения

10 часов

Цель задания

- Освоить работу с Yandex DataTransfer
- Научиться выполнять автоматизацию работы с Yandex Data Processing (Hadoop + Spark)
- Освоить работу с топиками Apache Kafka с помощью PySpark-заданий (Yandex Data Processing)
- Построить дашборды в DataLens для визуализации результатов

Инструменты для выполнения ДЗ

Чтобы выполнить задания, вам понадобятся:

- Облачные сервисы: Yandex Cloud (Data Processing, DataLens, Managed Service for Apache Airflow, Managed Service for Apache Kafka)
- Базы данных: Hive/Spark SQL, YDB
- Язык запросов: SQL (HiveQL, Spark SQL, YQL)
- Инструменты разработки: GitHub (для хранения SQL-скриптов), Yandex Object Storage

Правила приёма работы

Прикрепить в ЛМС ссылки на репозиторий GitHub. Репозиторий должен содержать подробный отчёт о проделанной работе. Настройки репозитория должны быть public.

Важно:

- убедитесь, что по ссылке есть доступ, так как иногда доступ может быть закрыт для другого логина;
- название должно содержать фамилию и имя студента и название задания.

Критерии оценивания итогового задания

Критерии оценивания	Баллы
Задание 1. Работа с Yandex DataTransfer	2
Задание 2. Автоматизация работы с Yandex Data Processing при помощи Apache AirFlow	2
Задание 3. Работа с топиками Apache Kafka® с помощью PySpark-заданий в Yandex Data Processing	3
Задание 4. Визуализация в DataLens	1
Итого	8 баллов

- Максимальное количество баллов, которое можно получить, отлично выполнив все требования, заявленные в критериях оценки, — 8.
- Преподаватель может добавить 1–2 балла к этой оценке за творческий подход к выполнению проекта, проработку решения, выходящую за рамки программы и расширяющую функционал проекта.

Описание задания

В рамках развития корпоративной платформы данных необходимо интегрировать новые источники данных и реализовать дополнительные ETL/Streaming-процессы для расширения аналитических возможностей системы.

Задание 1. Работа с Yandex DataTransfer

[Ссылка на документацию](#)

Требуется перенести данные из Managed Service for YDB в объектное хранилище Object Storage. Выполнить необходимо с использованием сервиса Data Transfer.

1. **Создать БД Yandex DataBase.**
2. **Подготовить данные:**
 - transactions_v2

Данные можно взять [здесь](#) или подготовить их самостоятельно. Примерный объём не менее 30 Мб. Примерный формат:

call_id,call_time,client_id,region_code,campaign_type,call_status,client_response,duration_sec,follow_up_required

call_20260501_001,2026-05-01 11:42:15,client_4412,DE - HE,credit_card_offer,answered,interested,184,true

3. **Создать трансфер в Object Storage.**
4. **Проверить работоспособность трансфера.**

Все SQL-скрипты (YQL) необходимо сохранить в репозитории домашней работы (GitHub).

Задание 2. Автоматизация работы с Yandex Data Processing при помощи Apache AirFlow.

[Ссылка на документацию](#)

Требуется обрабатывать файлы (parquet или CSV) из внешнего источника. Размер входящих файлов меняется в различные дни месяца.

Данные можно взять [здесь](#) или подготовить их самостоятельно.

1. **Подготовить инфраструктуру.**
2. **Подготовить PySpark-задание.**
 - Создать кластер Yandex Data Processing
 - Создать и запустить задание PySpark
 - Удалить кластер Yandex Data Processing
3. **Подготовить DAG-файл, запустить и проверить результат.**

Требуемый объём файла не менее 50 Мб. Примерная структура плоской таблицы:

application_id,event_time,customer_id,region_code,product_type,requested_amount,term_months,credit_score,risk_level,decision_status,approved_amount,channel,employee_review_flag,processing_time_sec

app_20260501_001,2026-05-01 09:14:22,cust_88421,DE - HE,cash_loan,12000,24,734,low,approved,12000,mobile,false,12

Задание 3. Работа с топиками Apache Kafka® с помощью PySpark-заданий в Yandex Data Processing.

[Ссылка на документацию](#)

Требуется настроить чтение топиков kafka для реализации потоковой аналитики.

- 1. Подготовить архитектуру**
- 2. Создать задания PySpark**
- 3. Разложить JSON в плоский вид**

Требуемый объём для передачи не менее 20 Мб. Пример JSON для отправки в топик:

```
{
  "application_id": "loan_784512",
  "customer": {
    "customer_id": "cust_441",
    "region": "DE-HE"
  },
  "loan": {
    "amount": 15000,
    "term_months": 36
  },
  "scoring": {
    "score": 712,
    "risk_level": "medium"
  },
  "documents": [
    {
      "type": "passport",
      "status": "verified"
    }
  ],
  "decision_status": "manual_review",
  "submitted_at": "2026-05-01T10:15:11Z"
}
```

Задание 4. Визуализация в DataLens.

С помощью Yandex DataLens построить **дашборды** для визуализации загруженных данных.

По завершении выполнения заданий **подготовьте подробный отчёт** в свободной форме с описанием проделанных действий.

Обратите внимание.

- На следующих вебинарах будет выделено время для консультации по выполнению задания. У вас будет возможность задать вопросы преподавателю и прояснить детали/сложности задания.
- Не забывайте останавливать сервисы в Яндекс облаке, чтобы вам хватило бесплатного ресурса на выполнение заданий.

Внимание! Представленное домашнее задание может быть рассмотрено в ходе онлайн-занятия (вебинара) для всех слушателей курса. Запись вебинара будет доступна всем слушателям курса в личном кабинете. Если ваша работа содержит персональные данные, коммерческую информацию или иную информацию ограниченного доступа, и вы возражаете против ее публичного разбора, обязательно укажите это, написав в комментарии к сдаваемой работе «В основу решения положена конфиденциальная информация». При отсутствии в домашнем задании указания на ограничение по конфиденциальности считается, что вы даете согласие на демонстрацию вашей работы для всех слушателей курса.